

Por extensión

Se listan explícitamente los elementos del conjunto.

$$A = \{a_1, a_2, \dots, a_n\} \text{ si es finito}$$

$$A = \{a_1, a_2, \dots, a_n, a_{n+1}, \dots\} \text{ si es infinito numerable}$$

Por comprensión

Se describe una propiedad que deben cumplir los elementos.

$$A = \{x \in S : x \text{ cumple una propiedad}\}$$

Observación

Un mismo conjunto puede escribirse de ambas maneras cuando se conoce una regla y/o una lista de elementos.

$$S = \{1, 2, 3, 4, 5, 6\} = \{x \in \mathbb{N} : 1 \leq x \leq 6\}$$

Definiciones:

- Un **evento** es un subconjunto del espacio muestral, es decir A es un evento si $A \subseteq S$.

Definición

A implica B si al ocurrir A ocurre B . Es decir:

$$A \subseteq B$$

Si todos los eventos elementales tienen la misma probabilidad:

$$P(A_1) = P(A_2) = \cdots = P(A_n) = p,$$

entonces,

$$np = 1 \quad \Rightarrow \quad p = \frac{1}{n}.$$

Definición: Un espacio muestral S se llama **equiprobable** si todos los eventos elementales tienen probabilidad $\frac{1}{n}$.

Definición


Si $P(A) > 0$, la **probabilidad condicional** de que ocurra B dado que ocurrió A es:

$$P(B | A) = \frac{P(A \cap B)}{P(A)}.$$

Casos particulares de probabilidad condicional

a) Si $A \subseteq B$, entonces:


$$P(B | A) = \frac{P(A \cap B)}{P(A)} = \frac{P(A)}{P(A)} = 1.$$



Casos particulares de probabilidad condicional

b) Si $A \cap B = \emptyset$, entonces:

$$P(B | A) = \frac{P(A \cap B)}{P(A)} = \frac{P(\emptyset)}{P(A)} = 0.$$



Teorema de la multiplicación para tres eventos

Si A_1, A_2, A_3 son tres eventos, entonces:

$$P(A_1 \cap A_2 \cap A_3) = P(A_1) P(A_2 | A_1) P(A_3 | A_1 \cap A_2)$$

Definición

Dos eventos A y B son **independientes** si y sólo si

$$P(A \cap B) = P(A) P(B).$$

Relación con probabilidad condicional

Si $P(B) > 0$, usando la definición:

$$P(A | B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)P(B)}{P(B)} = P(A).$$

Por lo tanto: si A y B son independientes, conocer que ocurrió B no altera la probabilidad de A .

Enunciado

Sea B un suceso cualquiera y

- ▶ $A_1, \dots, A_n$ una partición del espacio muestral S .
- ▶ Si $P(A_i) > 0$ para todo i ,

entonces:

$$P(B) = \sum_{i=1}^n P(B | A_i) P(A_i).$$

Enunciado

Sea B un suceso cualquiera con

- ▶ $P(B) > 0$.
- ▶ $A_1, \dots, A_n$ una partición del espacio muestral S .
- ▶ Si $P(A_i) > 0$ para todo i ,

Entonces, para cada $k = 1, \dots, n$:

$$P(A_k | B) = \frac{P(B | A_k) P(A_k)}{\sum_{i=1}^n P(B | A_i) P(A_i)}.$$

Definición

Dado un experimento aleatorio, sea S su espacio muestral asociado. Una **variable aleatoria** es una función que asigna a cada elemento del espacio muestral S un número real.

Definición

Sea X una v.a. discreta con rango finito

$$R_X = \{x_1, x_2, \dots, x_n\},$$

donde cada x_i es un número entero y x_{i+1} es el consecutivo de x_i .
Si

$$P(X = x_i) = \frac{1}{n} \quad \text{para todo } i,$$

entonces se dice que X tiene **distribución uniforme discreta**.

Definición

Sea X una variable aleatoria discreta con rango R_X y función de probabilidad $p(x_i) = P(X = x_i)$. La **esperanza o valor medio** de X es:

$$\mathbb{E}(X) = \sum_{x_i \in R_X} x_i p(x_i).$$

Teorema

Si $Y = g(X)$ es una función de la variable aleatoria discreta X , entonces la esperanza de Y es:

$$\mathbb{E}(Y) = \sum_{x_i \in R_X} g(x_i) p(x_i) = \sum_{x_i \in R_X} g(x_i) P(X = x_i)$$

$$= 50 \cdot 1 + 120 \mathbb{E}(X)$$

Si calculamos la esperanza de X llegaríamos al mismo resultado.

Enunciado

Sea X una variable aleatoria discreta y sean $a, b \in \mathbb{R}$. La esperanza de una función lineal de X se obtiene como:

$$\mathbb{E}(aX + b) = a \mathbb{E}(X) + b.$$

Esta propiedad es fundamental porque permite calcular el valor esperado de combinaciones lineales de variables sin necesidad de expandir toda la distribución.

Teorema

La varianza puede calcularse alternativamente como:

$$\text{Var}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$$

Propiedades fundamentales

Para cualquier variable aleatoria discreta X y constantes $a, b \in \mathbb{R}$:

- ▶ Para cualquier función h , $\text{Var}(h(X)) = \mathbb{E}([h(X) - \mathbb{E}(h(X))]^2)$
- ▶ $\text{Var}(aX + b) = a^2 \text{Var}(X)$
- ▶ $\sigma_{aX+b} = \sqrt{\text{Var}(aX + b)} = |a| \sigma_X$
- ▶ $\text{Var}(aX) = a^2 \text{Var}(X)$
- ▶ $\text{Var}(X + b) = \text{Var}(X)$

Definición

Un experimento binomial cumple las siguientes condiciones:

- ▶ Consta de n repeticiones idénticas de un ensayo.
- ▶ En cada repetición solo hay dos resultados posibles: **éxito** (E) o **fracaso** (F).
- ▶ Las repeticiones son independientes, lo que significa que el resultado de cualquier repetición particular no influye en el resultado de ninguna otra.
- ▶ La probabilidad de éxito $p = P(E)$ es constante en todas las repeticiones.

Si X es una v.a. binomial con parámetros n y p , lo denotaremos como $X \sim B(n, p)$.

Resultado

$$E[X] = np$$

Recordatorio: Fórmula para calcular la varianza

$$\text{Var}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$$

Paso 1: Cálculo de $\mathbb{E}[X^2]$

$$\begin{aligned}\mathbb{E}(X^2) &= \sum x^2 \cdot P(X = x) = 1^2 \cdot P(X = 1) + 0^2 \cdot P(X = 0) \\ &= 1 \cdot p + 0 \cdot (1 - p) = p\end{aligned}$$

Paso 2: Cálculo de $\text{Var}(X)$

$$\text{Var}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2 = p - (p)^2 = p - p^2 = p(1 - p)$$

Resultado

$$\text{Var}(X) = p(1 - p)$$

PROPOSICIÓN

Si $X \sim B(n, p)$, entonces:

$$\mathbb{E}(X) = np$$

$$V(X) = np(1 - p)$$

$$\sigma_X = dt(X) = \sqrt{np(1 - p)}$$

Contexto

La distribución geométrica modela el número de intentos necesarios hasta obtener el primer éxito en una secuencia de ensayos de Bernoulli independientes.

- ▶ se realizan repeticiones independientes e idénticas de un ensayo **hasta** el primer éxito
- ▶ Probabilidad de éxito constante: p

Función de probabilidad

$$P(X = k) = (1 - p)^{k-1} \cdot p \quad \text{para } k = 1, 2, 3, \dots$$

Interpretación

- ▶ $(1 - p)^{k-1}$: Probabilidad de $k - 1$ fracasos consecutivos
- ▶ p : Probabilidad de éxito en el k -ésimo intento

Notación

$$X \sim G(p)$$

Fórmula de la Fda para $k = 1, 2, 3, \dots$,

$$F(k) = P(X \leq k) = 1 - (1 - p)^k$$

es la probabilidad de tener éxito en los primeros k intentos.

PROPOSICIÓN

Si $X \sim G(p)$, entonces:

$$\mathbb{E}(X) = \frac{1}{p}$$

$$V(X) = \frac{1 - p}{p^2}$$

$$dt(X) = \frac{\sqrt{1 - p}}{p}$$

Contexto

Modela el número de éxitos al extraer una muestra **sin reemplazo** de una población finita que contiene dos tipos de elementos.

Ejemplo típico

De una urna con N bolillas:

- ▶ M bolillas rojas (éxitos)
- ▶ $N - M$ bolillas negras (fracasos)
- ▶ Se extraen n bolillas **sin reemplazo**
- ▶ X : Número de bolillas rojas extraídas

Notación

$$X \sim H(n, M, N)$$

Función de probabilidad

Si $X \sim H(n, M, N)$

$$p(k) = P(X = k) = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}$$

para $\max(0, n - (N - M)) \leq k \leq \min(n, M)$

Las restricciones son consecuencia de:

- ▶ k no puede ser menor que 0 ni mayor que n
- ▶ No se pueden extraer más éxitos de los que hay ($k \leq M$)
- ▶ No se pueden extraer más fracasos de los que hay ($n - k \leq N - M$)

Fórmulas

Si $X \sim H(n, M, N)$, entonces:

$$\mathbb{E}(X) = n \cdot \frac{M}{N}$$
$$\text{Var}(X) = n \cdot \frac{M}{N} \cdot \frac{N - M}{N} \cdot \frac{N - n}{N - 1}$$

Condición de aproximación

Cuando N es grande y n es pequeño relativo a N (al menos $n/N \leq 0.05$), la hipergeométrica se aproxima a una binomial:

$$H(n, M, N) \approx B(n, p = \frac{M}{N})$$

Contexto

La distribución de Poisson sirve para modelizar el número de eventos que ocurren aleatoriamente en el tiempo o en una región.

Definición formal

Una v.a. X con rango $R_X = \{0, 1, 2, \dots\}$ tiene distribución de Poisson con parámetro λ , $\lambda > 0$, si su f.d.p. es

$$p(k) = P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!} \quad \text{para } k = 0, 1, 2, \dots$$

Notación

$$X \sim P(\lambda)$$

Si X_t es la variable aleatoria que cuenta el número de eventos que ocurren en un proceso de Poisson en un intervalo de longitud t , entonces:

$$p(x) = P(X = x) = e^{-c \cdot t} \frac{(c \cdot t)^x}{x!} \quad \text{para } x = 0, 1, 2, \dots$$

Esto significa que X_t sigue una distribución de Poisson con parámetro:

$$\lambda_t = c \cdot t$$

Donde c es la **tasa de ocurrencia**, es decir, el número promedio de eventos por unidad de tiempo.

Aproximación Poisson-Binomial

Si $X \sim B(n, p)$ se puede demostrar que cuando n es grande y p pequeño, vale la siguiente aproximación: $np = \lambda$ constante:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k} \approx \frac{e^{-np} (np)^k}{k!} \quad \text{para } k \in R_X$$

Es decir, $X \approx P(np)$. Aquí $\approx$ significa que tiene aproximadamente esa distribución.

Ventajas de la aproximación

- ▶ Evita números combinatorios grandes
- ▶ Buena aproximación cuando $n \geq 20$ y $p \leq 0.05$ y muy buena si $n \geq 100$, $p \leq 0.01$ y $np \leq 20$.

Definición:

Una v.a. X es continua si existe $f(x) \geq 0$ tal que:

$$P(X \in B) = \int_B f(x) dx$$

para todo $B \subset \mathbb{R}$

A la función f la llamamos **función densidad de probabilidad**.

Propiedades:

1. $\int_{-\infty}^{\infty} f(x) dx = 1$
2. $P(a \leq X \leq b) = \int_a^b f(x) dx$
3. $P(X = a) = 0$

Definición

La esperanza de una v.a. continua X con f.d.p. $f(x)$ se define como

$$E(X) = \int_{-\infty}^{\infty} xf(x) dx$$

Si X es una v.a. continua con f.d.p. $f(x)$ y $h(X)$ es cualquier función de X , entonces

$$E(h(X)) = \int_{-\infty}^{\infty} h(x)f(x) dx$$

Propiedad

Propiedad:

$$V(aX + b) = a^2 V(X) \quad y \quad \sigma_{aX+b} = |a| \sigma_X$$

Definición

Una v.a. continua X tiene distribución uniforme en el intervalo $[a, b]$, con $a < b$, si su función de densidad es:

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{si } a \leq x \leq b \\ 0 & \text{caso contrario} \end{cases}$$

Notación: $X \sim U[a, b]$

Es fácil verificar que:

- ▶ $f(x) \geq 0, \forall x$
- ▶ $\int_{-\infty}^{\infty} f(x)dx = \int_a^b \frac{1}{b-a}dx = 1$

Navigation icons: back, forward, search, etc.

Propiedad fundamental

Para cualquier intervalo $[c, d] \subseteq [a, b]$:

$$P(c \leq X \leq d) = \frac{d - c}{b - a}$$

Para $X \sim U[a, b]$, la F.d.a. es:

$$F(x) = \begin{cases} 0 & \text{si } x < a \\ \frac{x-a}{b-a} & \text{si } a \leq x \leq b \\ 1 & \text{si } x > b \end{cases}$$

Para $X \sim U[a, b]$:

Esperanza

$$E(X) = \frac{a + b}{2}$$

Varianza

$$V(X) = \frac{(b - a)^2}{12}$$

Una variable aleatoria continua X tiene distribución exponencial con parámetro $\lambda > 0$ si su función de densidad es:


$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{si } x \geq 0 \\ 0 & \text{si } x < 0 \end{cases}$$

Notación: $X \sim \text{Exp}(\lambda)$

$$F(x) = 1 - e^{-\lambda x}$$

Propiedad:

Para la distribución normal estándar: $\Phi(-z) = 1 - \Phi(z)$



Propiedad

Si $X \sim N(\mu, \sigma^2)$, entonces:

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

Estandarización

Para calcular probabilidades de cualquier normal: si $X \sim N(\mu, \sigma^2)$

$$P(X \leq x) = P\left(\frac{X - \mu}{\sigma} \leq \frac{x - \mu}{\sigma}\right) = \Phi\left(\frac{x - \mu}{\sigma}\right)$$

Ejemplo

Si $X \sim N(100, 15^2)$, entonces:

$$P(X \leq 130) = P\left(Z \leq \frac{130 - 100}{15}\right) = \Phi(2) \approx 0.9772$$

Definición Formal

Sea (X, Y) una variable aleatoria bidimensional discreta. La **función de probabilidad puntual conjunta** $p : R_{XY} \rightarrow \mathbb{R}$ se define como:

$$\begin{aligned} p(x_i, y_j) &= P(\{X = x_i\} \cap \{Y = y_j\}) \\ &= P(X = x_i, Y = y_j) \quad \forall (x_i, y_j) \in R_{XY} \end{aligned}$$

y debe satisfacer:

1. $p(x_i, y_j) \geq 0 \quad \forall (x_i, y_j) \in R_{XY}$
2. $\sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) = 1$

Definición

Sea (X, Y) una variable aleatoria bidimensional discreta con función de probabilidad conjunta $p(x_i, y_j)$. Las **distribuciones marginales** se definen como:

$$p(x_i) = P(X = x_i) = \sum_{j=1}^m p(x_i, y_j) \quad (\text{Marginal de } X)$$

$$q(y_j) = P(Y = y_j) = \sum_{i=1}^n p(x_i, y_j) \quad (\text{Marginal de } Y)$$

Definiciones

En general definimos la función de probabilidad puntual de X condicional a Y como sigue:

$$p(x_i|y_j) = P(X = x_i \mid Y = y_j) = \frac{p(x_i, y_j)}{q(y_j)} \quad (X \text{ dado } Y)$$

Análogamente, definimos la función de probabilidad puntual de Y condicional a X :

$$q(y_j|x_i) = P(Y = y_j \mid X = x_i) = \frac{p(x_i, y_j)}{p(x_i)} \quad (Y \text{ dado } X)$$

Definición Formal

Sea (X, Y) una variable aleatoria bidimensional discreta. Sea $p(x_i, y_j)$ su f.d.p. conjunta y sean $p(x_i)$ y $q(y_j)$ las correspondientes funciones de probabilidad marginales de X e Y . Decimos que X e Y son variables aleatorias **independientes** si y sólo si:

$$p(x_i, y_j) = p(x_i)q(y_j) \quad \forall (x_i, y_j) \in R_{XY}$$

Concepto General

Dada una variable aleatoria bidimensional (X, Y) y una función $H : \mathbb{R}^2 \rightarrow \mathbb{R}$, definimos una nueva variable aleatoria:

$$Z = H(X, Y)$$

Teorema

Sea (X, Y) una variable aleatoria bidimensional discreta cuya f.d.p. conjunta es $p(x_i, y_j)$. Si $Z = H(X, Y)$, entonces:

$$E[Z] = \sum_{(x_i, y_j) \in R_{XY}} H(x_i, y_j) p(x_i, y_j)$$

Teorema para funciones lineales

Sea (X, Y) una variable aleatoria bidimensional y $a, b, c \in \mathbb{R}$

$$E[aX + bY + c] = aE[X] + bE[Y] + c$$

Definición

Una **combinación lineal** de n variables aleatorias es:

$$Z = a_1X_1 + a_2X_2 + \cdots + a_nX_n = \sum_{i=1}^n a_iX_i$$

donde $a_1, a_2, \dots, a_n$ son constantes reales.

Esperanza de una Combinación Lineal

$$E[Z] = E\left[\sum_{i=1}^n a_iX_i\right] = \sum_{i=1}^n a_iE[X_i]$$

Esperanza del Total usando Linealidad

$$\begin{aligned} E[X] &= E[X_1 + X_2 + X_3 + X_4 + X_5] \\ &= E[X_1] + E[X_2] + E[X_3] + E[X_4] + E[X_5] \\ &= 0.8 + 0.8 + 0.8 + 0.8 + 0.8 \\ &= 5 \times 0.8 = 4 \end{aligned}$$

Esperanza del Producto de Variables Independientes

En general la esperanza de un producto de variables aleatorias no es igual al producto de las esperanzas, pero...

Teorema: Caso Bidimensional (n=2)

Si X e Y son variables aleatorias **independientes**, entonces:

$$E[XY] = E[X]E[Y]$$

Demostración (caso discreto, vale también para el continuo):

$$\begin{aligned} E[XY] &= \sum_x \sum_y xy \cdot p(x, y) \\ &= \sum_x \sum_y xy \cdot p(x)q(y) \quad (\text{por independencia}) \\ &= \left(\sum_x xp(x) \right) \left(\sum_y yq(y) \right) = E[X]E[Y] \end{aligned}$$

Definición:

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$$

Varianza de la Suma

Para cualquier par de variables:

$$V[X + Y] = V[X] + V[Y] + 2\text{Cov}(X, Y)$$

Varianza de la Suma

Si X e Y son independientes ($\text{Cov}(X, Y) = 0$):

$$V[X + Y] = V[X] + V[Y]$$

Teorema

Sean $X \sim N(\mu_1, \sigma_1^2)$ e $Y \sim N(\mu_2, \sigma_2^2)$ variables aleatorias **independientes**. Entonces:

$$X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$

Teorema

Si $X_1, X_2, \dots, X_n$ son variables aleatorias independientes donde $X_i \sim N(\mu_i, \sigma_i^2)$ para todo $i = 1, 2, \dots, n$, entonces:

$$\sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right)$$

Teorema (Caso general)

Si $X_1, X_2, \dots, X_n$ son variables aleatorias independientes donde $X_i \sim N(\mu_i, \sigma_i^2)$ para todo $i = 1, 2, \dots, n$, y $a_1, a_2, \dots, a_n$ son constantes reales, entonces:

$$\sum_{i=1}^n a_i X_i \sim N\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right)$$

Teorema (Promedio muestral)

Si $X_1, X_2, \dots, X_n$ son variables aleatorias independientes e idénticamente distribuidas (i.i.d.) con $X_i \sim N(\mu, \sigma^2)$ para todo i , entonces:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Estandarización

Para calcular probabilidades con distribución normal, estandarizamos:

$$Z = \frac{T - \mu_T}{\sigma_T} = \frac{T - 2000}{40} \sim N(0, 1)$$

$$P(T \leq 1950) = P\left(\frac{T - 2000}{40} \leq \frac{1950 - 2000}{40}\right) = P\left(Z \leq -\frac{5}{4}\right)$$

Variable de interés

Definimos la variable $\bar{X}$ como el peso promedio de los 4 paquetes:

$$\bar{X} = \frac{X_1 + X_2 + X_3 + X_4}{4} = \frac{T}{4}$$

Aplicando el teorema del promedio de normales

Por el teorema: Si $X_i \sim N(\mu, \sigma^2)$ i.i.d., entonces:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Estandarización

Para calcular probabilidades con distribución normal, estandarizamos:

$$Z = \frac{\bar{X} - \mu}{\sigma_{\bar{X}}} = \frac{\bar{X} - 500}{10} \sim N(0, 1)$$

Enunciado del Teorema

Sean $X_1, X_2, \dots, X_n$ variables aleatorias **independientes e idénticamente distribuidas** (i.i.d.) con $E(X_i) = \mu$ y $V(X_i) = \sigma^2$. Para n grande, la distribución de $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ es **aproximadamente normal** con media μ y varianza σ^2/n . Formalmente, cuando n es grande:

$$P(\bar{X} \leq a) = P\left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq \frac{a - \mu}{\sigma/\sqrt{n}}\right) \approx \Phi\left(\frac{a - \mu}{\sigma/\sqrt{n}}\right)$$

$\bar{X}$ es llamado **promedio muestral** o **media muestral**.

En la práctica

Si $X_1, X_2, \dots, X_n$ son i.i.d., para n suficientemente grande:

$$\bar{X} \approx N\left(\mu, \frac{\sigma^2}{n}\right)$$

$$\sum_{i=1}^n X_i \approx N(n\mu, n\sigma^2)$$

Estandarización

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \frac{\bar{X} - 160}{6.3246}$$

$$P(\bar{X} < 150) = P\left(\frac{\bar{X} - 160}{6.3246} < \frac{150 - 160}{6.3246}\right) = P(Z < -1.5811)$$

Teorema

Sean $X \sim B(n_1, p)$ e $Y \sim B(n_2, p)$ variables aleatorias **independientes**. Entonces:

$$X + Y \sim B(n_1 + n_2, p)$$

Teorema

Si $X \sim B(n, p)$ y n es grande, entonces:

$$X \approx N(np, np(1-p))$$

o, equivalentemente:

$$Z = \frac{X - np}{\sqrt{np(1-p)}} \approx N(0, 1)$$

Fundamentación

Recordemos que $X = \sum_{i=1}^n X_i$ donde $X_i \sim \text{Bernoulli}(p)$ i.i.d.
Por TCL: $\frac{X - np}{\sqrt{np(1-p)}} \approx N(0, 1)$ cuando n es grande.

Reglas de corrección

- ▶ $P(X = k) \approx P(k - 0.5 \leq Y \leq k + 0.5)$
- ▶ $P(X \leq k) \approx P(Y \leq k + 0.5)$
- ▶ $P(X < k) \approx P(Y \leq k - 0.5)$
- ▶ $P(X \geq k) \approx P(Y \geq k - 0.5)$
- ▶ $P(X > k) \approx P(Y \geq k + 0.5)$

Teorema

Sean $X \sim P(\lambda_1)$ e $Y \sim P(\lambda_2)$ variables aleatorias **independientes**. Entonces:

$$X + Y \sim P(\lambda_1 + \lambda_2)$$

Teorema

Si $X \sim P(\lambda)$ y λ es grande, entonces:

$$X \approx N(\lambda, \lambda)$$

o, equivalentemente:

$$Z = \frac{X - \lambda}{\sqrt{\lambda}} \approx N(0, 1)$$

La aproximación es muy buena si $\lambda \geq 30$.

Aspecto	TCL Promedio	Binomial	Poisson
Distribución	Cualquiera	$B(n, p)$	$P(\lambda)$
Condición	$n \geq 30$	$np \geq 5, n(1 - p) \geq 5$	$\lambda \geq 30$
Media	μ	np	λ
Varianza	σ^2/n	$np(1 - p)$	λ

Puntos clave comunes

- Todas se basan en el Teorema Central del Límite
- Mejoran cuando el n aumenta
- Para variables discretas mejora si se aplica corrección por continuidad